

以機器學習技術自動判斷大林廠轉動機械運作之正常與異常情況

王淑麗¹

王朝民²

吳有基³

韓欽銓⁴

林昇³ 黃鈺榮⁵ 林顯圖⁵

江均賢³ 林錦垣³

¹台灣中油股份有限公司煉製研究所燃料及潤滑劑組

²台灣中油股份有限公司總工程師室

³國立聯合大學電機工程學系

⁴國立聯合大學資訊工程學系

⁵國立聯合大學材化博士學程

摘要

馬達廣泛應用於工業中，數量眾多，維修保養費龐大，然若未即時保養卻發生故障，將影響工場生產進度而致產能損失，故及早檢知運轉異常之馬達極為重要。本文針對抽油水馬達組的三種不同運轉狀態：正常、鬆開固定螺絲、以及馬達軸心偏移(偏心)，透過震動感測器及自製類比數位轉換器，進行資料採擷，然後對訊號做低通濾波的預處理和分幀的動作，再對每一幀以統計方法及梅爾頻率倒譜係數(Mel-Frequency Cepstral Coefficients, MFCC)進行時頻域的特徵擷取，再將分幀的特徵導入支持向量機(Support Vector Machine, SVM)中的糾錯輸出碼(error-correcting output codes, ECOC)，並以K-fold交叉驗證的方式訓練模型，經過測試，三種類別中，鬆螺絲震動訊號分類結果為最佳，準確度為98.9%，正常震動訊號和偏心震動訊號，準確度分別為90.3%和91.1%，整體測試準確度為94.2%，獲得不錯的效果，未來將進一步將本文所提方法導入實際場域，以即時方式進行分類預測，在馬達運轉異常辨識上可達到示警目的，以降低人力成本以及避免馬達損壞帶來的許多負面效應。

關鍵字：抽油水馬達、支持向量機、糾錯輸出碼、梅爾頻率倒譜係數

1. 前言

馬達廣泛應用於工業中，煉油廠及石化廠的馬達數量眾多，可高達上萬台，每年維修保養費用以千萬元計。然馬達在運作過程中或多或少會產生故障的問題，若未即時保養卻發生故障，將影響工場生產進度(如：降煉量、開爐延後、停爐等)而致產能損失。故，及早檢知運轉異常之馬達，而對其進行保養，可以避開突發性的故障，減少非計畫性影響生產產能的發生機會。

在目前馬達的保養標的挑選上，雖然有些挑選的原則[1]，如(1)高震動現象、(2)感覺異常的馬達、(3)較重要的工場、(4)較重要的馬達、(5)運轉時間較久的，然多數並非使用較科學的方式，常採取人為評估哪組馬達最容易損壞，進行保養，如：目測螺絲是否有鬆脫、軸心有偏心的狀況，或是憑經驗感覺觀測，這些方法雖說可行，但還是稍顯不足，並非用科學的手段做辨識，還是會有些異常馬達的狀況是無法挑選出來。

在以科學方式進行辨識的工作上，需要將受測物的運作物理量擷取出來，也就是需要感測器感測受測物的物理量。在馬達的運轉上，擷取其震動訊號是最直接也是簡易非侵入式不須停機就可達成的訊號擷取方式，僅需將震動感測器貼附在待測馬達上即可。本文即是以震動訊號來建構機械學習(machine learning)辨識模型，將震動數據代入模型進行訓練，讓電腦透過訊號的特徵，學習檢測馬達三種不同運轉狀態：正常、鬆開固定螺絲、以及馬達軸心偏移(偏心)，來克服傳統維護上人員經驗不足或容易疏忽之處。收集到的數據，經過預處理以及擷取特徵，再導入至以支持向量機(supporting vector machine, SVM)為基礎之機器學習模型，進行模型訓練，實現狀態分類。訓練完的模型最終以混淆矩陣(confusion matrix)的方式呈現評估模型準確度，期能導入至實際應用場域，在馬達運轉異常辨識上達到示警目的。

2. 研究方法

此次研究的標的物為抽油水馬達，如圖2-1，使用Wilcoxon Model 786A 加速規(accelerometer)，如圖2-1右上所示，採擷三種不同運轉狀態：正常、鬆開固定螺絲(圖2-1右下角)、以及馬達軸心偏移(偏心) (如圖左下角，調整螺絲讓軸心偏移)之震動訊號，透過自製類比數位轉換器(analog-to-digital converter, ADC)，如圖2-2，取樣率為977 Hz，將收集到的震動訊號，轉成數位訊號，讀入電腦中，儲存成Excel檔。每種狀態的資料採擷時間大約15分鐘。然後將資料進行處理，使用機器學習進行訓練，將不同馬達運轉狀態進行辨識及狀態預測。

2.1 整體流程

本文使用支持向量機(SVM)辨識抽油水馬達正異常震動訊號，處理流程如圖2-3，數據採擷過程是先在馬達正常運轉下，收集震動數據大約15分鐘，此時馬達是處在抽油狀態，收集到的檔案編號為1 (狀態為正常)。然後鬆開固定螺絲，收集震動數據大約15分鐘，在此過程中的後段時間，油被抽光，變成抽水，收集到的檔案編號為2 (狀態為鬆螺絲-抽油水)。為了驗證抽水及抽油對於此一狀態的影響，再次收集震動數據(鬆螺絲-抽水狀態)約15分鐘，收集到的檔案編號為3 (狀態為鬆螺絲-抽水)。然後將鬆開的固定螺絲鎖緊，進行偏心狀態下的震動數據收集，時間大約也是15分鐘，收集到的檔案編號為4 (狀態為偏心)。將檔案1資料標籤為正常震動訊號(1)，檔案2及3標籤為鬆螺絲震動訊號(23)，檔案4標籤為偏心震動訊號(4)。然後經過資料的預處理、分幀、特徵處理、正規化、K-fold交叉驗證法、SVM等步驟，訓練模型及辨識馬達的狀態。




圖2-1震動感測器測量抽油水馬達實體圖




圖2-2 自製類比數位轉換器

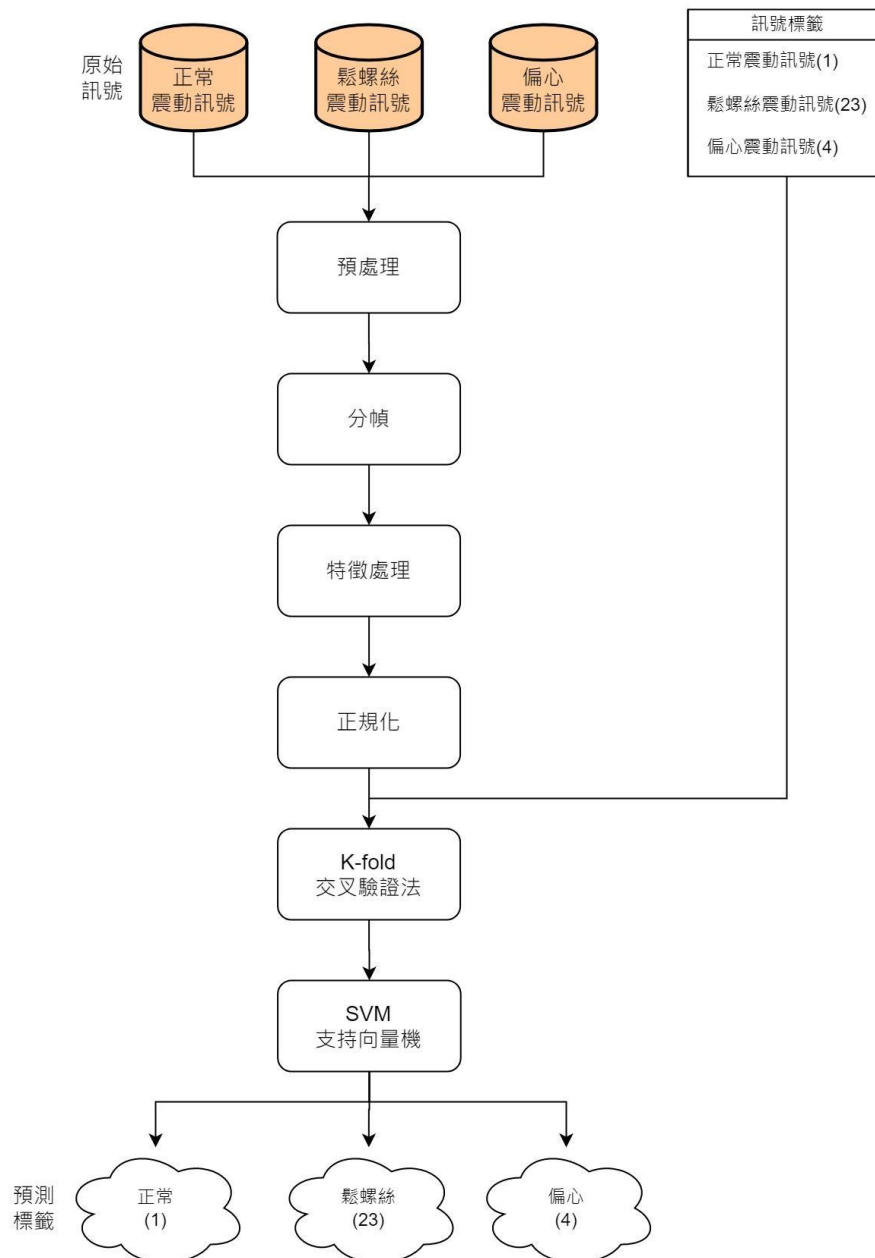


圖2-3 抽油水馬達正異常震動訊號演算法

2.2 預處理

將資料饋入至訓練模型前需要先做一些處理，濾除雜訊及啟動初期非穩態數值，讓訓練模型不致讀取到不必要的訊息，造成判斷失誤。本實驗所使用的數據取樣率為977 Hz，分為正常震動訊號、鬆螺絲震動訊號和偏心震動訊號，其中鬆螺絲震動訊號和偏心震動訊號為所要觀察的異常訊號，在抽油水機器數據收集中發現在開機時，也記錄到初期不必要的非穩態訊號，故大約在1.5V以下的無用訊號將會被去除，並視情況去除一些離散訊號使整體訊號穩定。之後將資料以低通濾波器，濾除200 Hz以上的訊號，保留主要的訊號。

2.3 分幀

由於收集到的三種訊號(正常震動訊號、鬆螺絲震動訊號和偏心震動訊號)長度約15分鐘或更長，取樣點為80~100萬，取樣點數過於龐大，如果將整段訊號做特徵處理會變得資料樣本數過小，所以先將訊號進行分幀，將訊號以5000取樣點

為一幀，並設置前後幀的重疊率為50%，也就是前後幀有2500取樣點為重複，目的是為了讓幀與幀之間都保有連續性，如圖2-4，目的是增進機器學習的準確性。三種不同狀態的分幀波形圖，如圖2-5，可以看得出，從訊號上是不容易區別這三種狀態的差異，因此，需要進一步做特徵處理，讓彼此之間的差異得以區別。

2.4 特徵處理

訊號分幀後，資料樣本數增加，但每幀的取樣點數還是有5000點，對於電腦來說還是不易判斷，需要將每一幀做特徵擷取，降低資料維度，便於電腦辨識處理。

由於震動訊號是屬於時間序列訊號，在時域分析上，如果將每一幀的震動訊號直接代入模型中，數據計算量大，不好處理，因此，本文將每幀的訊號進行統計分析，除計算每幀的平均值、平均偏差、標準差、第一四分位數、第三四分位數、四分位距、中位數、峰度、與偏度之外，也計算香濃熵(Shannon Entropy)、和譜熵(Spectral Entropy)，共取11個數值作為幀的時域上特徵，以降低資料維度，並保持訊號原有的特性樣貌。

在頻域的特徵擷取上，採用梅爾頻率倒譜係數(Mel-Frequency Cepstral Coefficients, MFCC)，是由於它是一種接近人耳判斷的頻譜分析，在低頻的區域會有較多的濾波器組，高頻的區域濾波器組則較少分布，比較稀疏，利用這種特性，求出12個梅爾頻率係數和1個訊框[2]。此外，還納入3個功率譜上的特徵，分別是功率譜最大值、功率譜最大值頻率和功率譜最大值能量百分比，共取16個數值作為幀的頻域上特徵。時域及頻域全部特徵加總起來共有27個特徵數值[3]。

2.5 K-fold

將每幀的特徵以及與其對應的標籤(正常震動訊號(1)、鬆螺絲震動訊號(23)和偏心震動訊號(4))，進行K-fold交叉驗證(K-fold Cross Validation) [4]，方式是輪流將分為K組資料集(K folds)中的一組資料集(fold)當作測試集，剩餘K-1組資料集做為訓練集，目的是讓所有資料都能被模型訓練和測試，流程如圖2-6。本文K設定為5，也就是每次模型訓練的訓練-測試比例為4:1，四組作為訓練集，一組做為測試集，每次模型訓練的測試集都使用不同組，如此重複五次，直到五組都測試過，然後將做出來的五次結果做平均，即為此一K-fold整體準確度。

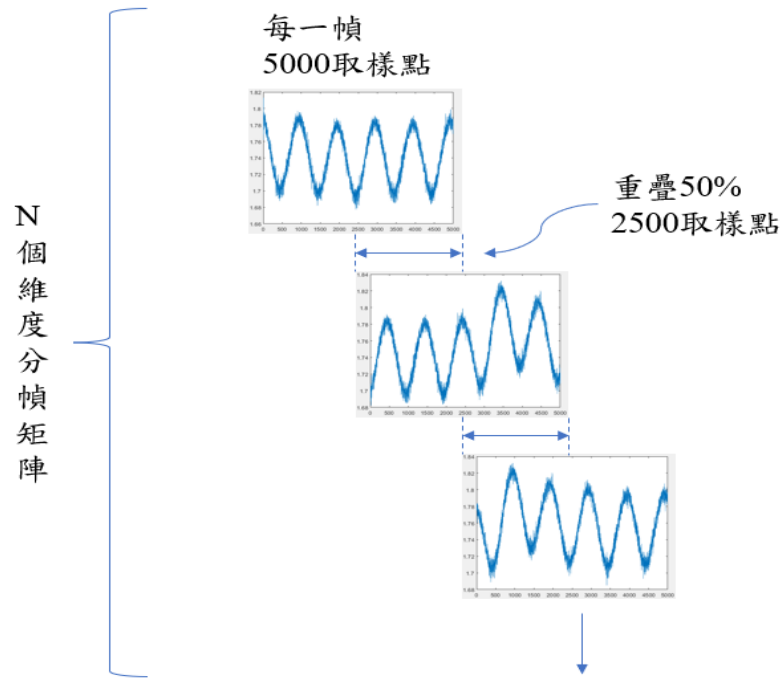


圖2-4 震動訊號分幀示意圖




圖2-5震動訊號(正常、偏心、鬆螺絲)分幀示意圖

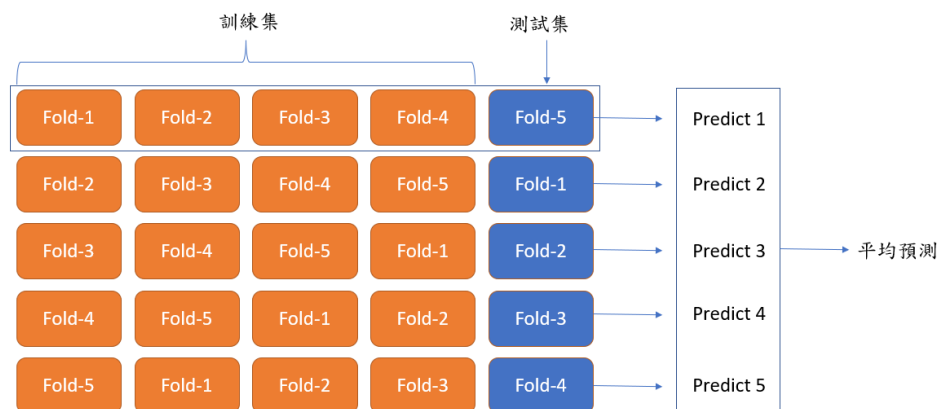


圖2-6 K-fold示意圖

2.6 支持向量機

邏輯回歸、支持向量機[5]等機器學習算法可以對二元數據集進行分類，但是無法處理超過 2 個目標類標籤的多類分類任務。對於多類分類或多標籤分類任務，我們需要使用某些技巧或者其他機器學習算法來訓練數據集。由於本次馬達運轉狀態有三類，故使用Matlab支持向量機中的糾錯輸出碼(error-correcting output codes, ECOC) [6], 函數為fitcecoc(), 它是一種最常用的MvM技術(many vs. many, 多對多)，可以將多類學習(multiclass learning)問題轉化成二元分類(binary classification)問題。ECOC的思想是將機器學習問題看做數據通信問題，並採用糾錯輸出碼對各類別進行編碼，因此在分類過程中能夠糾正某些二元分類器的錯誤輸出，從而提高分類器的預測精度。ECOC是一種監督式模型，需要先將訓練樣本的特徵(features)與標籤(label)代入其中，利用核函數(Kernel Function)中的多項式參數(polynomial)，將輸入特徵投放至高維空間中，將數據進行分類預測。

3. 結果

馬達三種運轉狀態下所量測數據，經過預處理及分幀後，各種狀態(資料集)的訊號樣本數(幀數)，如表3-1所示。分為正常震動訊號、鬆螺絲震動訊號和偏心震動訊號三類。

表3-1抽油水馬達資料集

| 資料集 | 正常 | 鬆螺絲 | 偏心 |
|-------|-----|-----|-----|
| 訊號(幀) | 358 | 546 | 386 |

由於每幀擷取出來的特徵數為27，屬高維度特徵，為了要在二維圖上展現ECOC-SVM的分類情況，使用Matlab提供的特徵選擇(feature selection)的方法，函數為sequentialfs() [7], 挑選最高貢獻的兩個特徵做為作圖的主軸，特徵選擇標準值如表3-2所示。根據求出的標準值(criterion value)決定兩個最高貢獻的特徵quantile25跟dominantFrequencyRatio做為二維圖的兩個軸，如圖3-1~圖3-2所示，在支持向量機內部會以將標籤們分成三群為目標，多數標籤出現在圖中的三個黃色區域，而有些則在藍色區域，代表屬於群與群之間的交界處，從圖中觀察到，在僅以quantile25跟dominantFrequencyRatio兩個特徵來進行SVM分類時，正常標籤與偏心標籤還是有些不易清楚地分類成功。因此，SVM需要一起使用其他特徵值，改善整體模型的分類預測效果。

表3-2 特徵選擇標準值

| 特徵(feature) | 標準值(criterion value) |
|--------------|----------------------|
| 1. meanValue | 0.0300388 |

| | |
|--------------------------------|-----------|
| 2. medianValue | 0.0358527 |
| 3. standardDeviation | 0.0271318 |
| 4. meanAbsoluteDeviation | 0.0319767 |
| 5. quantile25 | 0.0610465 |
| 6. quantile75 | 0.0300388 |
| 7. signalIQR | 0.0397287 |
| 8. sampleSkewness | 0.0319767 |
| 9. sampleKurtosis | 0.0310078 |
| 10. signalEntropy | 0.0300388 |
| 11. spectralEntropy | 0.0436047 |
| 12. dominantFrequencyValue | 0.0271318 |
| 13. dominantFrequencyMagnitude | 0.0329457 |
| 14. dominantFrequencyRatio | 0.231589 |
| 15. mfcc訊框 | 0.0329457 |
| 16. mfcc1 | 0.0290698 |
| 17. mfcc2 | 0.0416667 |
| 18. mfcc3 | 0.0300388 |
| 19. mfcc4 | 0.0397287 |
| 20. mfcc5 | 0.0339147 |
| 21. mfcc6 | 0.0387597 |
| 22. mfcc7 | 0.0455426 |
| 23. mfcc8 | 0.0542636 |
| 24. mfcc9 | 0.0455426 |
| 25. mfcc10 | 0.0484496 |
| 26. mfcc11 | 0.0591085 |
| 27. mfcc12 | 0.0300388 |

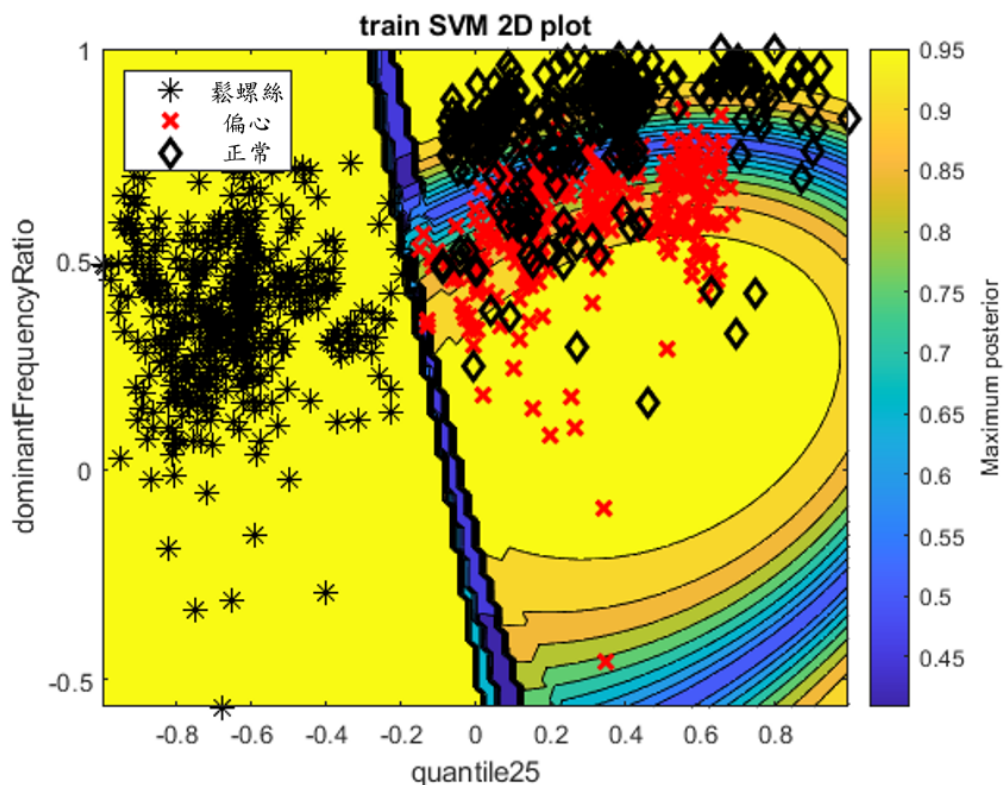


圖3-1支持向量機二維圖(訓練)

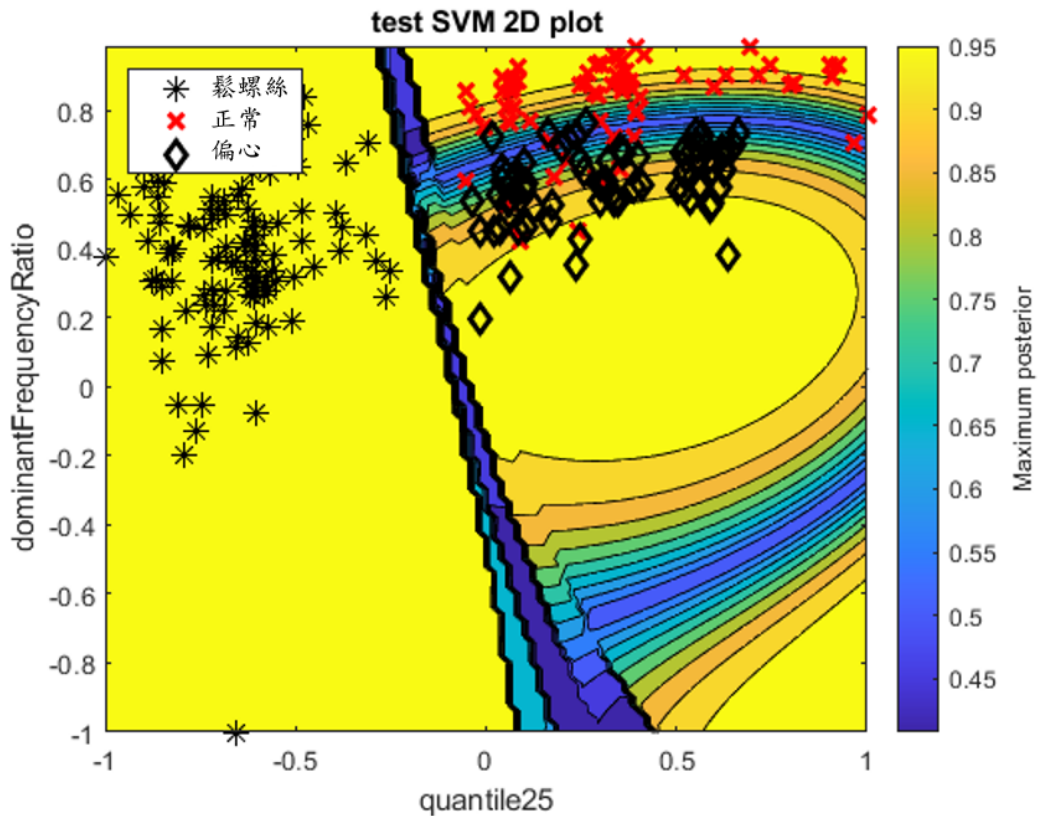


圖3-2支持向量機二維圖(測試)

考慮樣本資料的所有27個特徵值，並將資料分成5等分(5-fold)，經過ECOC訓練並預測分類，觀察混淆矩陣數值來評估模型訓練的好壞。因為是分三類，故混淆矩陣為3 x 3呈九宮格形式，其中的數字表示為幀數，Y軸為真實標籤(True Class)，X軸為預測標籤(Predicted Class)。

由於在5-fold交叉驗證過程中，樣本資料會隨機打亂分5等分，因此，我們執行20次的5-fold，求出20次訓練模型的平均預測準確度，結果如圖3-3~圖3-4所示，分別為訓練和測試的最終結果，每張圖片中左圖矩陣中數字為20次5-fold使用的幀數，右圖矩陣中數字為該對應幀數占該樣本標籤數的百分比。




圖3-3 20次5-fold訓練混淆矩陣




圖3-4 20次5-fold測試混淆矩陣

從圖3-3觀察結果，訓練階段的整體準確度為99.7%，狀態為正常的分類準確度為99.6%，狀態為偏心的分類準確度為99.5%，狀態為鬆螺絲的分類準確度為100%。從圖3-4觀察模型針對測試集資料的分類預測結果，整體分類預測準確度為94.2%，狀態為正常的分類預測準確度為90.3%，狀態為偏心的分類預測準確度為91.1%，狀態為鬆螺絲的分類預測準確度為98.9%。

4. 結論

本文成功地針對抽油水馬達組的三種不同運轉狀態：正常、鬆開固定螺絲、以及馬達軸心偏移(偏心)之震動訊號，透過自製類比數位轉換器，進行資料採擷，然後將資料經過預處理，分幀後，以統計分析方法擷取其時域的11個數值、以MFCC擷取其頻域的12個係數和1個訊框、加上3個功率普的特徵，共有27個特徵數值，導入ECOC支持向量機，以5-fold交叉驗證方式訓練模型，並重複試驗20次，獲得不錯的分類預測效果。在針對測試集，三種類別中，鬆螺絲震動訊號上結果為最佳，準確度為98.9%，可以很有效地預測，預測的結果幾乎都正確，而正常震動訊號和偏心震動訊號，準確度分別為90.3%和91.1%，相較於鬆螺絲訊號的預測效果表現是稍顯差一點，不過整體上使用ECOC支持向量機的演算法預測能力還算是不錯的，整體測試準確度為94.2%。未來將進一步將本文所提方法導入實際場域，以即時方式進行分類預測，在馬達運轉異常辨識上可達到示警目的，以降低人力成本以及避免馬達損壞帶來的許多負面效應。

5. 參考資料

- [1] 王淑麗, 王朝民, 黃玠華, 李孟鴻, 李彥賢, 謝金龍, 李英齊, (2020), AI 圖像辨識應用於轉動機械電流頻譜預知保養-硫磺工場壓縮機案例, 石油季刊, 第56卷, 第4期, pp.31-42
- [2] D. Y. Oh, I. D. Yun, "Residual Error Based Anomaly Detection Using Auto-Encoder in SMD Machine Sound," *Sensors (Basel, Switzerland)*, vol.18, no.5, 1308.
- [3] Matlab使用梅爾頻譜係數與時域分析於訊號上的應用, [Online] Available: <https://www.mathworks.com/matlabcentral/fileexchange/65286-heart-sound-classifier>
- [4] H. Ling, C. Qian, W Kang, C. Liang, H. Chen, "Combination of Support Vector Machine and K-Fold cross validation to predict compressive strength of concrete in marine environment", *Construction and Building Materials*, vol.206,

pp.355-363, May. 2019.

- [5] D. R. Sawitri, D. A. Asfani, M. H. Purnomo, I. K. E. Purnama and M. Ashari, "Early detection of unbalance voltage in three phase induction motor based on SVM," 2013 9th IEEE International Symposium on Diagnostics for Electric Machines, Power Electronics and Drives (SDEMPED), 2013, pp. 573-578.
- [6] Matlab為支持向量機或其他分類器擬合多類模型, [Online] Available: <https://www.mathworks.com/help/stats/fitcecoc.html>
- [7] Matlab使用自定義的標準特徵選擇方法, [Online] Available: <https://www.mathworks.com/help/stats/sequentialfs.html>